

Universidad Autónoma de Tamaulipas

Facultad de Ingeniería y Ciencias

Reporte Proyecto Final.

Sonia Lizbeth Muñoz Barrientos

Maestría en Ciencias e Ingeniería de Datos

Ciudad Victoria, Tamaulipas

1. Introducción

En la actualidad, las plataformas digitales se han convertido en una fuente importante de información para el sector turístico, ya que los usuarios comparten constantemente opiniones y experiencias sobre los lugares que visitan. Estas reseñas representan una valiosa fuente de conocimiento, debido a que permiten conocer la percepción de los visitantes respecto a distintos sitios, así como identificar aspectos positivos, neutros o negativos de su experiencia.

Sin embargo, debido a que estas opiniones se encuentran en formato textual no estructurado y en grandes volúmenes, su análisis manual resulta complejo y poco eficiente. Esto dificulta extraer información útil de manera rápida y objetiva, especialmente cuando se desea comparar diferentes ciudades o lugares turísticos con base en la percepción expresada por los usuarios.

La minería de opiniones y el análisis de sentimiento ofrecen una alternativa para procesar automáticamente las reseñas y transformarlas en información estructurada. Mediante técnicas de clasificación de texto, es posible identificar la polaridad de las opiniones y generar indicadores que faciliten el análisis comparativo entre diferentes lugares. Por ello, el presente proyecto se enfoca en analizar reseñas turísticas mediante técnicas de minería de texto, con el propósito de identificar cuáles lugares presentan una mejor percepción entre los visitantes.

2. Problemática

A pesar de la gran cantidad de reseñas disponibles sobre ciudades y lugares turísticos, no siempre es sencillo determinar de manera objetiva cuáles sitios presentan una mejor percepción por parte de los visitantes. Las opiniones se encuentran dispersas en grandes volúmenes de texto, lo que dificulta su revisión, organización e interpretación manual.

Esta situación limita la posibilidad de comparar lugares turísticos de forma sistemática, identificar cuáles concentran una mayor proporción de opiniones positivas o reconocer aquellos que generan impresiones neutrales o negativas. En consecuencia, se vuelve necesario contar con un mecanismo que permita transformar estas reseñas en información estructurada y comparable. Ante ello, la aplicación de técnicas de minería de opiniones y clasificación de sentimientos representa una alternativa para analizar automáticamente las reseñas y generar indicadores que faciliten la identificación de los lugares con mejor percepción.

3. Justificación

El presente proyecto se justifica por la necesidad de analizar de manera objetiva la percepción que los visitantes tienen sobre diferentes lugares turísticos a partir de las reseñas publicadas en plataformas digitales. Estas opiniones constituyen una fuente importante de información, ya que reflejan experiencias reales de los usuarios; sin embargo, su volumen y naturaleza textual dificultan su análisis manual. Mediante el uso de técnicas de minería de opiniones y clasificación de sentimientos, es posible procesar estas reseñas y convertirlas en información estructurada que permita identificar tendencias positivas, neutrales y negativas. De esta manera, el proyecto facilita la comparación entre distintos lugares y ciudades, permitiendo reconocer cuáles presentan una mejor percepción.

Además, este trabajo aporta una aplicación práctica de la minería de texto en el ámbito turístico, al combinar análisis de sentimiento, generación de indicadores y visualización de resultados. Asimismo, el desarrollo de un tablero visual y de un módulo de predicción para nuevas reseñas fortalece el valor práctico del proyecto, ya que permite no solo analizar la percepción histórica de los lugares turísticos, sino también clasificar automáticamente nuevas opiniones ingresadas por el usuario.

4. Solución propuesta

Como solución a la problemática planteada, se propone el desarrollo de un sistema de minería de opiniones orientado al análisis de reseñas turísticas, con el fin de identificar cuáles lugares presentan una mejor percepción por parte de los visitantes.

Para ello, se utilizará un dataset de conjunto de reseñas turísticas asociadas a ciudades y lugares específicos; esta fuente de datos cuenta con un total de 1.5 millones de reseñas y diferentes columnas

como: *City, Place, Review, Rating, Name, Date, Raw_review*, como se muestra en la figura 1. Estas reseñas serán procesadas mediante técnicas de minería de texto, con el propósito de preparar la información para su análisis. Posteriormente, se construirá una variable de sentimiento con tres categorías: positivo, neutral y negativo, tomando como negativo las reseñas que cuenten con un rating de 1 y 2, neutral a las de 3 y a las positivo de 4 y 5; la cual permitirá abordar el problema como una tarea de clasificación multiclase.

```
df.head()
```

	City	Place	Review	Rating	Name	Date	Raw_Review
0	Aamby Valley City	19 Degree North	aamby valley beautiful place clear blue skies ...	5	Anonymous	NaN	Aamby valley is a beautiful place with its cle...
1	Aamby Valley City	19 Degree North	executed obt akshay thanx team thoroughly enjo...	4	Anonymous	NaN	Very well executed obt by Akshay.... Thanx as ...
2	Aamby Valley City	19 Degree North	awesome experience atv tracts obstacles mainta...	5	Anonymous	NaN	Awesome experience at the ATV\nTracts and obst...
3	Aamby Valley City	19 Degree North	visited aamby valley yesterday short excursion...	4	Anonymous	NaN	we visited the Aamby Valley yesterday for shor...
4	Aamby Valley City	19 Degree North	far mumbai place finest adventure places visit...	5	Anonymous	NaN	Not far from Mumbai, this place is one of the ...

Figura 1: Dataset utilizado extraído de la plataforma [Kanggle](#)

A partir de esta información, se entrenarán y evaluarán distintos modelos de clasificación de texto, utilizando representaciones basadas en TF-IDF, la cual permite representar el texto en forma numérica al asignar mayor peso a los términos más relevantes dentro de cada reseña y menor peso a aquellas palabras frecuentes que aportan poca capacidad de discriminación. Esto facilita que los modelos de clasificación identifiquen patrones lingüísticos asociados a cada clase de sentimiento. Una vez seleccionado el modelo con mejor desempeño, este se empleará para clasificar las reseñas y generar indicadores de percepción por lugar y por ciudad, tales como proporciones de sentimientos, promedio de calificación e índice de percepción.

Finalmente, se desarrollará un tablero visual que permita explorar los resultados de manera interactiva, así como un módulo de predicción para clasificar nuevas reseñas ingresadas por el usuario. De esta forma, la solución propuesta no solo permitirá analizar la percepción histórica de los lugares turísticos, sino también ofrecer una herramienta práctica para la interpretación y visualización de la información obtenida.

5. Resultados obtenidos

Como parte del desarrollo del proyecto, después de haber explorado el dataset lo siguiente a realizar fue construir una variable de sentimiento a partir de las calificaciones del conjunto de datos, definiendo tres clases: negativo, neutral y positivo, con el código mostrado en el fragmento de código 1, posteriormente fue aplicado, mostrando estos resultados en la figura 2. El análisis exploratorio mostró un desbalance entre clases, con predominio de reseñas positivas con un 81 %, mostrado en la figura ??.

Listing 1: Etiquetar el sentimiento según el rating asignado

```
# Crear variable de sentimiento a partir de Rating
def etiquetar_sentimiento(rating):
    if rating in [1, 2]:
        return 'negativo'
    elif rating == 3:
        return 'neutral'
    elif rating in [4, 5]:
        return 'positivo'
    else:
        return None
```

...	City	Place	Review	Raw_Review	Rating	Sentiment
0	Aamby Valley City	19 Degree North	aamby valley beautiful place clear blue skies ...	Aamby valley is a beautiful place with its cle...	5.0	positivo
1	Aamby Valley City	19 Degree North	executed obt akshay thanx team thoroughly enjo...	Very well executed obt by Akshay.... Thanx as ...	4.0	positivo
2	Aamby Valley City	19 Degree North	awesome experience atv tracts obstacles mainta...	Awesome experience at the ATV\InTracts and obst...	5.0	positivo
3	Aamby Valley City	19 Degree North	visited aamby valley yesterday short excursion...	we visited the Aamby Valley yesterday for shor...	4.0	positivo
4	Aamby Valley City	19 Degree North	far mumbai place finest adventure places visit...	Not far from Mumbai, this place is one of the ...	5.0	positivo
5	Aamby Valley City	19 Degree North	yearn adrenaline rush place try atv forester m...	if you yearn for the adrenaline rush then this...	5.0	positivo
6	Aamby Valley City	19 Degree North	great adventure place recommend x jungle safar...	A great adventure place .I recommend there 4x...	5.0	positivo

Figura 2: Dataset ya con las reseñas etiquetadas.




Figura 3: Distribución de las clases: positivo, neutro y negativo.

Posteriormente, se entrenaron distintos modelos de clasificación de texto utilizando representaciones TF-IDF, mostrado en el Cuadro 2. Se evaluaron los modelos Naive Bayes, Regresión Logística y LinearSVC, tanto con la columna *Review* como con *Raw_Review*. Los resultados mostraron que la representación basada en *Review* produjo un mejor desempeño en comparación con *Raw_Review*.

Listing 2: Código utilizado para vectorizar el texto con TF-IDF

```
X_train_tfidf = tfidf.fit_transform(X_train)
X_test_tfidf = tfidf.transform(X_test)
```

Entre los modelos probados, Regresión Logística y LinearSVC presentaron los mejores resultados. Aunque LinearSVC obtuvo la mayor exactitud, la Regresión Logística mostró un comportamiento más equilibrado entre las tres clases, por lo que fue seleccionado como modelo final.

A partir de las predicciones del modelo, se generaron tablas resumen por ciudad y por lugar, incluyendo indicadores como total de reseñas, proporción de sentimientos, promedio de calificación e índice

de percepción. Con ello, fue posible identificar los lugares con mejor y peor percepción. Finalmente, se implementó un tablero visual en Streamlit que permite explorar los resultados de las tablas mencionados anteriormente, observándose en la Figura 4 clasificar nuevas reseñas ingresadas por el usuario 5.




Figura 4: Dashboard del resumen de reseñas obtenidas por ciudades.

Las reseñas deben ser ingresadas en el idioma inglés y pueden ser un texto normal o palabras clave como: *beautiful*, *normal* o *dirty*. A manera de ejemplo para mostrar el funcionamiento del modelo se ingresa la frase: **The place was beautiful, clean and very peaceful!** y el modelo nos muestra que la reseña es buena, mostrándose en la Figura 6.

Escribe una reseña y el modelo predecirá si es negativa, neutral o positiva.

Escribe aquí tu reseña

Ejemplo: beautiful place clean peaceful excellent service

Predecir sentimiento

Figura 5: Pantalla mostrada para el ingreso de una nueva reseña y ser clasificada.




Figura 6: Resultados de una nueva reseña ingresada.

6. Evaluación de modelos

Con el objetivo de identificar el modelo más adecuado para la clasificación de sentimientos en reseñas turísticas, se evaluaron tres algoritmos de clasificación de texto utilizando la columna *Review*: Naive Bayes, Regresión Logística y LinearSVC. La evaluación se realizó mediante las métricas *accuracy*, precisión, *recall* y *F1-score*, poniendo especial atención en el *F1-score macro*, debido al desbalance entre clases presente en el conjunto de datos.

En el caso de Naive Bayes, los resultados mostraron un desempeño deficiente en las clases *negativo* y *neutral*, con valores de *F1-score* de 0.02 en ambos casos. Aunque obtuvo una exactitud de 0.8155, el modelo presentó un sesgo importante hacia la clase *positivo*, alcanzando un *recall* de 1.00 en esta categoría, pero prácticamente ignorando las clases minoritarias, mostrados en el Cuadro 1. Esto indica que, a pesar de una exactitud aparentemente aceptable, su capacidad de discriminación entre las tres clases fue limitada.

Cuadro 1: Resultados de clasificación con Naive Bayes usando la columna *Review*

Clase	Precisión	Recall	F1-score	Soporte
Negativo	0.90	0.01	0.02	13164
Neutral	0.50	0.01	0.02	40870
Positivo	0.82	1.00	0.90	236849
Accuracy		0.8155		290883
Macro avg	0.74	0.34	0.31	290883
Weighted avg	0.78	0.82	0.74	290883

Por su parte, la Regresión Logística mostró una mejora considerable en todas las métricas. Este modelo alcanzó una exactitud de 0.9261 y un *F1-score macro* de 0.8530, el más alto entre los modelos evaluados. Además, presentó un comportamiento más equilibrado entre las tres clases, con valores de *F1-score* de 0.82 para *negativo*, 0.78 para *neutral* y 0.96 para *positivo*, mostrados en el Cuadro 2. Estos resultados indican que la Regresión Logística fue capaz de identificar adecuadamente tanto la clase mayoritaria como las clases menos representadas.

Cuadro 2: Resultados de clasificación con Regresión Logística usando la columna *Review*

Clase	Precisión	Recall	F1-score	Soporte
Negativo	0.76	0.88	0.82	13164
Neutral	0.69	0.90	0.78	40870
Positivo	1.00	0.93	0.96	236849
Accuracy		0.9261		290883
Macro avg	0.81	0.90	0.85	290883
Weighted avg	0.94	0.93	0.93	290883

En el caso de LinearSVC, se obtuvo la mayor exactitud global, con un valor de 0.9507, así como un *F1-score weighted* de 0.9510. Sin embargo, su *F1-score macro* fue de 0.8374, ligeramente inferior al obtenido por la Regresión Logística. Aunque este modelo mostró un excelente desempeño en la clase *positivo* y un buen comportamiento en *neutral*, su rendimiento en la clase *negativo* fue menor que el de Regresión Logística, con un *F1-score* de 0.69, mostrados en el Cuadro 3.

Cuadro 3: Resultados de clasificación con LinearSVC usando la columna *Review*

Clase	Precisión	Recall	F1-score	Soporte
Negativo	0.71	0.67	0.69	13164
Neutral	0.81	0.86	0.84	40870
Positivo	0.99	0.98	0.99	236849
Accuracy		0.9507		290883
Macro avg	0.84	0.84	0.84	290883
Weighted avg	0.95	0.95	0.95	290883

De manera general, la comparación entre modelos mostró que Naive Bayes no resultó adecuado para este problema debido a su sesgo hacia la clase mayoritaria. LinearSVC alcanzó el mejor desempeño en términos de exactitud global, mientras que la Regresión Logística presentó el mejor equilibrio entre clases, reflejado en el mayor *F1-score macro*, observado en el cuadro 4. Debido a que el conjunto de datos presenta desbalance y se busca una clasificación más justa entre las tres categorías de sentimiento, se seleccionó la Regresión Logística como modelo final del sistema.

Cuadro 4: Comparación general de modelos de clasificación

Modelo	Accuracy	Precision_macro	Recall_macro	F1_macro	F1_weighted
Naive Bayes	0.815500	0.739006	0.339895	0.312955	0.735376
Regresión Logística	0.926084	0.814426	0.904828	0.853016	0.930658
LinearSVC	0.950654	0.836775	0.838852	0.837362	0.950968

Con base en los resultados obtenidos, se observó que Naive Bayes no fue adecuado para el problema de clasificación multiclase, debido a su sesgo hacia la clase mayoritaria. Aunque LinearSVC obtuvo la mayor exactitud global, la Regresión Logística presentó el mejor *F1-score macro*, lo que indica un comportamiento más balanceado entre las tres clases. Por ello, este modelo fue seleccionado como la alternativa final para el sistema propuesto.

7. Conclusiones

El presente proyecto permitió comprobar que las técnicas de minería de opiniones y clasificación de sentimientos son útiles para analizar reseñas turísticas y transformar información textual no estructurada en indicadores comparables de percepción. Los resultados mostraron que la representación preprocesada de las reseñas, contenida en la columna *Review*, resultó más adecuada para la tarea de clasificación que la versión original *Raw_Review*. Asimismo, se observó que, aunque LinearSVC alcanzó una mayor exactitud global, la Regresión Logística presentó un mejor equilibrio entre clases, razón por la cual fue seleccionada como modelo final.

A partir de las predicciones obtenidas, fue posible generar indicadores por ciudad y lugar, permitiendo identificar cuáles sitios presentan una percepción más favorable por parte de los visitantes. Además, la implementación de un dashboard y de un módulo para clasificar nuevas reseñas fortaleció el valor práctico del proyecto, al facilitar la visualización e interpretación de los resultados. Este trabajo demuestra que la minería de opiniones puede constituir una herramienta valiosa para el análisis de percepción en el ámbito turístico, especialmente cuando se busca comparar lugares a partir de grandes volúmenes de reseñas.